

На правах рукописи

Sign

**Манолов Александр Иванович**

**Биоинформатический анализ изменчивости генного состава  
прокариот, в том числе в ассоциации с патогенностью**

Специальность 1.5.8 —  
«Математическая биология, биоинформатика»

**Автореферат**  
диссертации на соискание учёной степени  
кандидата биологических наук

Москва — 2021

Работа выполнена в Федеральном государственном бюджетном учреждении ”Федеральный научно-клинический центр физико-химической медицины Федерального медико-биологического агентства”.

Научный руководитель: доктор биологических наук, член-корреспондент РАН  
**Ильина Елена Николаевна**

Официальные оппоненты: **Фамилия Имя Отчество,**  
доктор физико-математических наук, профессор,  
Не очень длинное название для места работы,  
старший научный сотрудник  
**Фамилия Имя Отчество,**  
кандидат физико-математических наук,  
Основное место работы с длинным длинным длин-  
ным длинным названием,  
старший научный сотрудник

Ведущая организация: Федеральное государственное бюджетное образо-  
вательное учреждение высшего профессиональ-  
ного образования с длинным длинным длинным  
длинным названием

Защита состоится **DD mmmmmmmm YYYY г. в XX часов** на заседании диссер-  
тационного совета **Д 123.456.78** при **Название учреждения** по адресу: **Адрес.**

С диссертацией можно ознакомиться в библиотеке **Название библиотеки.**

Отзывы на автореферат в двух экземплярах, заверенные печатью учреждения,  
просьба направлять по адресу: **Адрес,** ученому секретарю диссертационного со-  
вета **Д 123.456.78.**

Автореферат разослан **DD mmmmmmmm**2021 года.  
Телефон для справок: **+7 (0000) 00-00-00.**

Ученый секретарь  
диссертационного совета  
**Д 123.456.78,**  
**д-р физ.-мат. наук**

**Sign** **Фамилия Имя Отчество**

## Общая характеристика работы

**Актуальность темы.** Геном прокариот представляет собой сложно организованную структуру. Помимо кодирующих и регуляторных областей, в нем имеется ряд элементов, необходимых для взаимодействия ДНК с молекулярными комплексами, осуществляющими процессы транскрипции, репликации и репарации. Пространственная укладка генетического материала в клетке не случайна и выполняет ряд регуляторных функций. Подобные наблюдения меняют представление о геноме, как о простом хранилище последовательностей генов расположенных в случайном порядке, и позволяют говорить об архитектуре генома — закономерностях, которые необходимы для успешного функционирования живой клетки.

К настоящему времени известен ряд элементов геномной организации. Гены, продукты которых необходимы клетке в больших количествах, расположены рядом с сайтом начала репликации, поскольку в быстро делящихся клетках такое расположение позволяет повысить уровень их экспрессии за счет увеличения копияности матричной ДНК. Пространственная укладка ДНК может сближать гены, расположенные в разных областях линейной последовательности, что оказывается полезно для генов, кодирующих регулятор и его мишени. Экспериментально было установлено, что действие глобальных регуляторов, таких как гистоноподобный белок H-NS, зависит от местоположения генов мишеней. Склонность к транскрипции (уровень экспрессии генов, не зависящий от их последовательности) значительно меняется в зависимости от положения гена в хромосоме. Взаимодействие РНК-полимераз, возникающее за счет изменения уровня суперскрученности ДНК, может играть роль в регуляции транскрипции соседних генов.

Геномные перестройки и горизонтальный перенос генов могут приводить к изменению оптимального расположения генов и других элементов генома, что может приводить к снижению жизнеспособности организма. Известно, что изменения в геномах преимущественно локализуются в отдельных местах — ”горячих” точках. Возможно, эти участки свободны от ”архитектурных” ограничений, и таким образом более толерантны к изменениям. Возможно, эти участки имеют некоторые признаки, способствующие более высокой частоте происходящих изменений. Нельзя исключить возможность, что ”горячие” точки возникли в результате генетического дрейфа а их расположение случайно и не обладает функциональным значением. Какие из этих вариантов, и в какой степени, реализуются в действительности, к настоящему моменту, неизвестно: локализация ”тихих” консервативных участков и ”горячих” высокоизменчивых областей не имеет общепринятых объяснений. Для проведения исследований в данной области необходим инструмент, позволяющий находить и анализировать области

генома с повышенной и пониженной изменчивостью. Разработка и применение подобного инструментария и стала основной темой данной работы.

**Целью** данной работы является разработка программного конвейера для выявления высокоизменчивых областей геномов прокариот и применение его для анализа изменчивости в локусах генома *Escherichia coli*, ассоциированных с болезнью Крона.

Для достижения поставленной цели необходимо было решить следующие **задачи**:

1. Разработать алгоритм оценки уровня изменчивости геномов, основанный на их графовом представлении.
2. Сравнить профили изменчивости геномов принадлежащих различным родам, видам и подвиновым структурам прокариот.
3. Оценить вклад различных факторов геномной организации в уровень изменчивости генома.
4. Разработать алгоритм визуализации подграфов, соответствующих отдельным локусам генома.
5. Разработать алгоритм поиска и выявить в геноме *E. coli* опероны, которые значимо чаще встречаются в изолятах от пациентов с болезнью Крона чем в изолятах от здоровых людей.

**Научная новизна:** Предложенный в нашей работе подход, насколько нам известно, был первым предложенным и реализованным методом для количественной оценки изменчивости генома.

Насколько нам известно, мы впервые провели сравнительный анализ расположения областей повышенной изменчивости. Мы обнаружили, что некоторые высокоизменчивые локусы генома могут сохранять свое расположение у представителей близкородственных видов.

### **Практическая значимость**

Изменчивость генома — важный фактор в возникновении патогенных штаммов бактерий и приобретении устойчивости к антибиотикам. Знание закономерностей подобных изменений важно для разработки оптимальных методов контроля над появлением штаммов бактерий, угрожающих жизни и здоровью людей. Возможно, полученные знания о закономерностях изменчивости и консервативности различных областей генома окажутся полезными при создании новых последовательностей геномов в области синтетической биологии.

### **Основные положения, выносимые на защиту:**

1. Графовое представление геномов позволяет эффективно проводить поиск областей генома с повышенной изменчивостью.
2. Визуализация в виде графа позволяет компактно представлять сравнение больших выборок геномов (порядка сотен и тысяч геномов).
3. Геномы представителей различных филогрупп и филогенетически близких видов имеют консервативно расположенные области повышенной изменчивости (расположенные в местах генома с одинаковым генным контекстом).

4. В геномах изолятов *E. coli* от пациентов с болезнью Крона значимо чаще выявляются опероны захвата сорбозы, захвата гемина, утилизации глиоксилата, утилизации пропандиола, синтеза и экспорта капсульных полисахаридов.

**Достоверность** предложенного метода обосновывается результатами компьютерного моделирования. Результаты находятся в соответствии с результатами, полученными другими авторами. Основные результаты работы докладывались на конференциях: "Итоговая научно-практическая конференция ФГБУ ФНКЦ ФХМ ФМБА России" (18-19 декабря 2019 года, Москва), "ПОСТГЕНОМ 2018" (29 октября - 2 ноября, Казань), "Биотехнология: состояние и перспективы развития" (20–22 февраля 2017 года, Москва, ), "Высокопроизводительное секвенирование в геномике" (Новосибирск, 18–23 июня 2017 года), "4th World Congress on Targeting Microbiota" (17-19 октября 2016, Париж).

**Личный вклад.** Автором были предложены подходы графового представления набора генов в геномах и оценки геномной вариабельности на основе выбора подграфа. Написан код на языках R, perl и Snakemake для графового представления набора геномов и автоматизации анализа геномных последовательностей (исправлении ошибок в гомополимерных областях, поиска контаминаций в наборе прочтений, построения ортогрупп, филогенетического анализа). Проведена сборка последовательностей геномов изолятов *E. coli* полученных от пациентов с болезнью Крона и проведено сравнение их с геномами комменсальных штаммов. Проведен анализ расположения областей повышенной изменчивости у различных родов, видов и внутривидовых структур прокариот.

**Публикации.** Основные результаты по теме диссертации изложены в 12 печатных изданиях, 6 из которых изданы в периодических научных журналах, индексируемых Web of Science и Scopus, 6 — в тезисах докладов.

Диссертационная работа была выполнена при поддержке гранта российского научного фонда №16-15-00258 "*E. coli* как мишень терапии при болезни Крона" (руководитель Побегуц О.В.).

**Объем и структура работы.** Диссертация состоит из введения, четырех глав, заключения и приложения. Полный объем диссертации XXX страниц текста с XX рисунками и 1 таблицей. Список литературы содержит XXX наименование.

## **Методология и методы исследования**

### **Анализ изменчивости геномов отдельных видов прокариот**

#### **Отбор последовательностей геномов для анализа геномной вариабельности**

Для анализа геномной изменчивости *E. coli* мы использовали 327 геномов данного организма доступные в базе RefSeq на момент ноября 2017 года и собранных до уровня репликонов ("финишированная" сборка). Для анализа изменчивости

в различных филогруппах *E. coli* нами были отобраны пять геномов — представителей наиболее крупных филогрупп данного организма (подбор проводился на основе литературных данных); затем для каждого представителя были выбраны 100 наиболее близких по нуклеотидному составу геномов, доступных в базе RefSeq. Для поиска наиболее близких последовательностей геномов мы проводили выравнивание программой *musmer* и суммарную длину выровненных участков использовали в качестве меры сходства последовательностей.

Для анализа внутривидовых структур у *Pseudomonas aeruginosa*, *Pseudomonas fluorescens* и *Neisseria gonorrhoeae* нами были выгружены все полногеномные последовательности, доступные в RefSeq. Для каждого вида в отдельности было построено филогенетическое дерево при помощи утилиты ParSNP v1.2. На основании полученных филогенетических деревьев мы выбрали (визуальным анализом, основываясь на количестве геномов и изолированности от иных клад) от двух до четырех клад дерева.

Для анализа других видов прокариот мы собрали набор последовательностей геномов всех видов, для которых было доступно не менее 50 последовательностей геномов в базе данных RefSeq. При наличии более 100 последовательностей геномов, в анализ включались 100 случайно выбранных последовательностей. Таким образом была сформирована выборка из 143 видов прокариот, включая два вида архей.

## Анализ геномной варибельности

Белок кодирующие последовательности во всех загруженных геномах были аннотированы с помощью программы Prokka ver 1.11. Гены были отнесены к ортогоруппам с помощью OrthoFinder ver. 2.2.6.

Скрипты на языке Python, содержащиеся в разработанном нами приложении GCB, использовались для оценки уровня изменчивости генома и создания подграфов вокруг интересующих областей генома. Принципы их работы описаны в соответствующих разделах главы Результаты. В разработке приложения приняли участие: Конанов Д.Н., Федоров Д.Е., Верещагин Р.И.

Визуализация подграфов проводилась в программе Cytoscape. Для формализации определения областей генома с повышенной изменчивостью мы использовали критерий Тьюки, основанный на межквартильном расстоянии.

Статистическая обработка и визуализация данных мы проводили на языке R. Для определения коэффициентов корреляции Спирмена использовали функцию *cor*. Статистическая значимость корреляций определялась при помощи функции *cor.test*. Индексы согласованности признаков с филогенетическим деревом (retention index) рассчитывались с использованием функции RI из библиотеки *phangorn* для языка R. Для построения линейных моделей использовалась функция *lm* языка R.

Для построения филогенетического дерева различных видов рода *Bacillus* мы выравнивали транслированные последовательности всех ортологических однокопийных генов при помощи программы muscle, преобразовали их в выравнивания кодонов с помощью pal2nal и построили дерево с помощью iqtree v1.6 с опцией ModelFinder Plus (оптимальный подбор эволюционной модели); конвейер snakemake для этих шагов доступен по адресу [https://github.com/paraslonic/orthosnake/blob/tree/Snakefile\\_tree](https://github.com/paraslonic/orthosnake/blob/tree/Snakefile_tree).

Поиск областей синтении мы проводили с помощью программы nuster (при сравнении последовательностей геномов различных штаммов одного вида), либо программы Mauve (при сравнении последовательностей геномов принадлежащих различным видам).

Для определения профагов в геномах мы использовали онлайн сервис Phaster.

Для нормировки матрицы частот хромосомных контактов использовалась функция *normalizeCore.performIterativeCorrection* из библиотеки gcMapExplorer.

## **Сборка и анализ геномов *E. coli* от пациентов с болезнью Крона**

### **Группа пациентов и клинический материал**

Пациенты были отобраны из двух клинических центров (ЦНИИ гастроэнтерологии и Государственного научного центра колопроктологии) в Москве, Российская Федерация, с 2012 по 2014 год. В исследование были включены десять пациентов. Критерии включения были следующими: возраст старше 18 лет, болезнь Крона была диагностирована эндоскопически и гистологически подтверждена. Критериями исключения были признаки неопределенного колита, инфекционные заболевания, недавнее лечение антибиотиками. Для исследования были собраны три типа образцов: 1) образцы кала; 2) биопсийный материал, полученный в ходе эндоскопического исследования; 3) жидкое содержимое подвздошной кишки. В подборе пациентов и организации сбора материала принимали участие: Щербаков П.Л., Маев И.В., Павленко А.В., Андреев Д.Н., Халиф И.Л.

### **Выделение изолятов *E. coli***

Выделение *E. coli* выполняли следующим образом. Приблизительно 0,05 мл объема фекалий помещали в 0,5 мл стерильного буфера (PBS), перемешивали на вортексе до гомогенности, аликвоту разбавляли примерно в  $10^6$  раз. Затем 0,1 мл полученной жидкости наносили на чашки со средой LB. После инкубации в течение ночи при 37°C изолированные колонии идентифицировали с помощью программного обеспечения Matrix Assisted Laser Desorption / Ionization (MALDI) Biotyper (Bruker Daltonics, Германия) с использованием масс-спектрометра Microflex LT (Bruker Daltonics, Германия). Для экстракции ДНК

все штаммы *E. coli* выращивали в бульоне LB при 37°C при встряхивании (200 об/мин) в течение ночи и собирали центрифугированием.

### **Экстракция ДНК и геномное секвенирование**

Геномную ДНК из отдельных культур экстрагировали с помощью набора QIAamp DNA Mini (Qiagen) в соответствии с протоколом производителя. Экстрагированная ДНК (100 нг для каждого образца) была разрушена на фрагменты размером 200 – 300 пар нуклеотидов с помощью системы Covaris S220 (Covaris, Woburn, Massachusetts, USA). Эмульсию ПЦР проводили с помощью набора Ion PGM Template OT2 200 (Life Technologies). Секвенирование ДНК выполняли с помощью Ion Torrent PGM (Life Technologies) с чипом Ion 318 и набором Ion PGM Sequencing 200 v2 (Life Technologies).

Получение культур и секвенирование проводилось в геномном центре ФНКЦ ФХМ при участии Кострюковой Е.С., Бабенко В.В., Карповой И.Ю., Лисициной Е.С.

Всего было получено 28 геномных последовательностей *E. coli* от 10 пациентов с болезнью Крона.

### **Сборка генома, исправление ошибок в гомополимерных областях**

Для сборки последовательностей геномов мы применяли программы Mira 4.0 и SPADES 3.10.0 с настройками, соответствующими типу секвенирования (Ion Torrent).

Каждая сборка проверялась на наличие возможных контаминаций (последовательностей нецелевого организма) при помощи скрипта, написанного на языке R и доступного по адресу: [https://github.com/paraslonic/BacPortrait/blob/master/portrait\\_spades.r](https://github.com/paraslonic/BacPortrait/blob/master/portrait_spades.r).

Данный скрипт отображает каждый контиг (отдельный фрагмент сборки) на диаграмме с ГЦ-составом и глубиной покрытия контига; дополнительно отображается информация о таксономической аннотации выбранного числа контигов.

Для технологии секвенирования Ion Torrent характерно наличие значительного количества ошибок в определении копийности нуклеотидов, особенно в гомополимерных областях. Для исправления данного типа ошибок, которые могут приводить к ошибкам сборки и искусственному сдвигу рамки считывания в кодирующих последовательностях (CDS), нами был разработан следующий метод. Проводилось картирование прочтений на сборку; поиск позиций с вставками либо делециями в картированных прочтениях при помощи утилиты VarScan; выравнивание областей сборки вокруг найденных позиций при помощи программы BLAST на базу nt (NCBI); выбор варианта последовательности, который соответствует лучшему выравниванию BLAST и представлен в прочтениях с частотой не ниже 25%. Этот метод уменьшает количество артефактных мутаций в сборке примерно в 2,5 раза (оценка основана на сравнении сборок считываний Ion



Torrent до и после исправления с считываниями более точных технологий секвенирования, таких как Illumina, SOLID и Sanger). Вычислительный конвейер для данной процедуры доступен по адресу: [www.github.com/paraslonic/НомоНомо](http://www.github.com/paraslonic/НомоНомо).

## **Сбор внешних данных**

Подбор последовательностей геномов *E. coli* с охарактеризованным источником выделения проводился на основе анализа литературных источников. Было отобрано 23 последовательности генома комменсальных штаммов *E. coli* (выделенных от здоровых людей), 4 последовательности генома изолятов, полученных от пациентов с болезнью Крона, 29 последовательностей геномов изолятов полученных от пациентов с иными заболеваниями, для которых кишечная палочка была описана как инфекционный агент.

## **Поиск ортогрупп**

Полученные последовательности геномов аннотировали с помощью программы PROKKA 1.7. Информация об оперонной структуре была получена из базы данных DOOR. Ортогруппы (группы гомологий включающие как ортологичные, так и паралогичные гены) были получены с помощью программы OrthoFinder v1.0.8.

Статистический анализ представленности генов и оперонов в последовательностях генома комменсальных штаммов *E. coli*, либо штаммов, полученных от пациентов с болезнью Крона, проводился при помощи скриптов на языке R, принцип работы которых описан ниже.

В организации работы и интерпретации полученных результатов принимали участие: Говорун В.М., Ракитина Д.В., Гарушянц С.К..

## **Результаты**

### **Графовое представление геномов**

Нами был предложен и реализован метод представления набора геномов в виде графа. Гены, относящиеся к одной ортогруппе, представляются в виде узла графа, а ребра отражают взаимное расположение генов в геномах. Ребро проводится между двумя узлами в том случае, если соответствующие гены расположены по соседству хотя бы в одном геноме; чем в большем количестве геномов наблюдается такое расположение генов, тем выше вес ребра (рисунок 1).

Предложенная схема требует уточнения в случае, когда несколько генов из одной геномной последовательности принадлежат к одной ортогруппе (мы будем называть такие гены паралогами). Мы предложили два подхода представления паралогичных генов в графе. В первом случае мы игнорируем паралогичные гены и не добавляем их в граф. Во втором — мы проводим процедуру "ортологизации" паралогичных генов: гены из ортогруппы добавляем в




Рис. 1 — Представление контекста генов в виде графа. Рассматриваем три гипотетических генома, состоящих из 6-7 генов. Гены показаны стрелками, цветом и буквами обозначены гены, относящиеся к одной ортогруппе. В нижней части рисунка показано графовое представление для данного набора геномов.

граф с некоторым суффиксом, при этом гены, имеющие одинаковый контекст, добавляются с одним и тем же суффиксом. В нашей программной реализации пользователь может выбирать применяемый подход.

## Оценка изменчивости геномов при помощи графового представления

Для исследования изменений генного состава в отдельном локусе генома, мы разработали процедуру построения подграфа, включающего только определенную область интереса референсного генома. Мы предложили использовать подсчет количества путей в соответствующем подграфе в качестве меры локальной изменчивости. В случае, если в некотором регионе не происходит изменений генного состава, то подграф представляет из себя простую структуру с одним возможным путем (способом обхода узлов). В случае, если в данной области происходят изменения, то в подграфе появляются новые пути. Чем больше различных вариантов сочетаний генов наблюдаются в геномных последовательностях, тем больше путей в соответствующем подграфе.

Оценка локальной вариабельности производится для одного выбранного гена референсного генома с учетом окна (смежных генов), размер которого

задается пользователем. Алгоритм расчета состоит в следующем. Вначале строится референсная цепочка узлов, после чего происходит подсчет путей, которые огибают узел (то есть начинаются по одну сторону, а заканчиваются – по другую). Для подсчета числа путей в графе мы применили вероятностный подход, что позволили увеличить скорость вычислений. Поиск одного пути происходит, начиная с первого узла цепочки, и затем случайным образом выбираются последующие вершины, пока путь не вернется в референсную цепочку, либо пока не будет достигнуто максимальное количество переходов. Совершается фиксированное количество итераций поиска путей, каждый новый уникальный путь запоминается. Количество найденных различающихся путей мы считаем мерой локальной изменчивости.

## **Верификация метода оценки локальной изменчивости**

Для верификации предложенного алгоритма и его программной реализации мы использовали компьютерное моделирование изменений геномных последовательностей. Для каждого локуса моделируемого генома мы задавали определенный уровень изменчивости, затем вероятностным образом изменяли генный состав, получая множество различающихся геномов, и оценивали наблюдаемую вариабельность при помощи предложенного нами подхода. Изменения генового состава происходили за счет вставки, удаления либо перемещения генов, а также инверсий фрагментов генома. Вероятность инверсий была в 100 раз меньше вероятностей остальных событий, а размер области для инверсии выбирался случайно из экспоненциального распределения. Локализация событий изменений генового состава выбиралась на каждом шаге случайно, в соответствии с распределением уровня вариабельности. Значения локальной вариабельности задавались в соответствии с одним из типов профилей: пилообразным, ступенчатым либо синусоидальным. Значения коэффициента  $R^2$  между исходно заданным уровнем изменчивости и тем, что был оценен при помощи графового подхода, составили 0.95, 0.77 и 0.8 для ступенчатого, синусоидального и пилообразного профиля, соответственно, корреляции имели статистическую значимость с  $p - value < 10^{-10}$ .

## **Анализ расположения областей повышенной изменчивости в геномных последовательностях кишечной палочки**

Для проведения данного анализа мы собрали коллекцию из 327 геномов бактерии *E. coli*, доступных в базе данных RefSeq, построили группы гомологии при помощи программы Orthofinder и применили разработанной нами метод оценки уровня геномной вариабельности; в качестве референсного генома был выбран геном штамма *E. coli* LF82, изолированного от пациента с болезнью Крона. На рисунке 2 показан профиль изменчивости и области расположения профагов, островов патогенности, генов рекомбиназ (для выявления следов мобильных

элементов генома), жизненно необходимых генов (мутации в которых являются летальными) и генов транспортных и рибосомных РНК.




Рис. 2 — Профиль вариабельности генома *Escherichia coli* LF82. Цветом обозначены острова патогенности, профаги, гены, ассоциированные с мобильными элементами генома, жизненнонеобходимые гены, гены транспортных и рибосомных РНК. Области повышенной изменчивости содержат меньше жизненнонеобходимых генов. Профаги и острова патогенности обладают повышенным уровнем изменчивости по сравнению с остальной частью генома. Вертикальные линии с подписями *ter* и *ori* показывают места начала и окончания репликации, соответственно.

Можно заметить, что участки генома, содержащие жизненно необходимые гены, как правило, мало изменчивы, а к высокоизменчивым областям генома относятся профаги и острова патогенности. При этом, наблюдаются также высокоизменчивые области генома, в которых отсутствуют признаки мобильных элементов; причины их высокой изменчивости остаются неизвестными. Гены транспортных РНК не проявляют явной ассоциации с профилем изменчивости. Гены рибосомной РНК находятся преимущественно в мало изменчивых областях генома.

Время существования вида *E. coli* оценивается в несколько десятков миллионов лет; возникает вопрос об устойчивости расположения "горячих" областей генома с течением времени. Мы провели сравнение профилей изменчивости подвидовых структур кишечной палочки. Для создания набора геномов мы выбрали по одному представителю из наиболее крупных филогенетических клад (филогрупп А, В1, В2, Е) и подобрали для каждого из них по сто ближайший

геномов из базы NCBI RefSeq. Затем мы рассчитали профили изменчивости для каждой филогруппы в отдельности и сравнили их между собой. Результат сравнения показан на рисунке 3, серым цветом обозначены блоки синтении, оранжевым – области нахождения профагов.




Рис. 3 — Сравнение профилей вариабельности представителей пяти филогрупп *E. coli* LF82. Оранжевым цветом выделены области, определенные как профаговые. Блоками серого цвета показаны области синтении. Показаны профили для штаммов: O157:H7 (филогруппа E), IA11 (B1), K12 (A), UMN026 (D), LF82 (B2).

Сравнение показывает, что ряд областей генома с повышенной изменчивостью присутствуют во всех или в большинстве филогрупп, что, по-видимому, свидетельствует об их существовании на протяжении значительной части времени жизни вида. Часть из этих областей соответствуют местам расположения профагов и их устойчивость можно объяснить сайт специфичным характером встраивания данных элементов. Одна из устойчивых "горячих" точек (выделена линией красного цвета) не имеет выявленных признаков мобильных элементов генома. Значительная часть "горячих" областей геномов является местами встройки фагов, что особенно заметно на примере филогруппы E (верхний профиль на рисунке 3), для которой была описана вирусная экспансия, значительно удлинившая геномную последовательность (на рисунке длины геномов приведены к одинаковой ширине, но о размере генома можно судить по координатным осям ниже профилей изменчивости).

Имеются также и "холодные" области генома с низкой вариабельностью во всех филогруппах. Длина этих участков может значительно превышать длины, характерные для оперонов, и достигать величин порядка миллиона пар оснований (например, область, выделенная зеленой линией на рисунке 3).

## **Алгоритмизация подхода выявления оперонов, наличие которых ассоциировано с определенным признаком.**

Предположим, что у нас есть некоторый признак, по которому мы можем разбить набор геномов на группы и наша задача — установить, какие гены значимо чаще (либо реже) встречаются в одной из групп. Простым и распространенным методом анализа, в подобном случае, является вычисление статистики и оценка значимости по каждому отдельному гену. Затем необходимо применить поправку на множественное сравнение, так как иначе следует ожидать множество ложно положительных результатов. В случае, если работа ведется на данных о полной последовательности генома, имеется большое количество анализируемых генов (порядка  $10^3 - 10^4$ ), а размеры групп, как правило, незначительны (порядка  $10^1 - 10^2$ ), что приводит к тому, что после поправки на множественное сравнение, ни один из анализируемых генов не проходит даже низкие пороги на значимость. В качестве одного из способов преодоления описанной выше проблемы мы предложили использовать информацию об организации генов в опероны для поиска значимых ассоциаций. Рассматривая оперон как структурную единицу, мы значительно сокращаем количество анализируемых признаков.

**Алгоритм поиска генетических ассоциаций** На входе необходимо иметь два или более набора геномных последовательностей и выбрать один референсный геном для которого известна оперонная структура. Первым шагом выполняется построение групп гомологий и оценка статистической значимости их неравной представленности в сравниваемых выборках. Затем ищутся опероны, в которых количество найденных ассоциированных генов выше, чем ожидалось бы при случайном распределении генов по оперонам. Для оценки ожидаемого количества генов при их случайном распределении мы предложили использовать два подхода. Первый основан на пермутациях таблицы соответствий генов и оперонов. Второй предполагает расчет ожидаемого значения исходя из распределения Пуассона, параметр которого рассчитывается как доля значимо ассоциированных генов среди общего числа генов в референсном геноме. Финальным шагом является проведение поправки на множественное сравнение, но уже не для генов, а для оперонов, количество которых, как правило, значительно ниже общего количества генов.

**Поиск оперонов, значимо чаще встречающихся у изолятов бактерий *E. coli*, изолированных от людей с болезнью Крона** В анализе были использованы геномные последовательности 51 изолятов *E. coli*, 27 из которых были получены от пациентов с болезнью Крона, 24 — от здоровых людей. При помощи программы OrthoFinder мы получили 11885 групп гомологии. Далее, при помощи точного теста Фишера оценили статистическую значимость их неравномерной распространенности между группами.

Следующим шагом мы осуществили описанный выше тип анализа, для поиска значимо дифференциально представленных оперонов. Информация об

оперонах была взята из базы данных DOORS. В качестве референсного генома мы использовали геном *E. coli* LF82 - данный штамм был изолирован из пациента с болезнью Крона и является модельным в исследованиях адгезивно-инвазивного фенотипа у кишечной палочки. Затем, мы провели 10000 случайных перестановок соответствий между генами и оперонами. Для каждой перестановки мы вычисляли зависимость количества генов с  $p\text{-value} < 0.05$  от длины оперона. Визуализация сравнения наблюдаемых и полученных при случайных перестановках результатов показана на рисунке 4. Опероны, для которых наблюдаемое число генов было выше, чем максимальное количество генов при случайных перестановках, считались статистически значимо пере- либо недопредставленными (в пермутационном тесте  $p\text{-value} < 0.0001$ ).




Рис. 4 — Зависимость доли генов в оперонах, с уровнем значимости  $p\text{-value} < 0.05$ , от количества генов входящих в оперон. Пунктирная линия показывает максимальные значения, полученные при проведении 10000 случайных сопоставлений генов и оперонов. Синим цветом выделены точки, соответствующие оперонам, которые неравномерно представлены между группами согласно пермутационному тесту.

Так, например, оперон утилизации пропандиола состоит из 19 генов, из которых 14 генов (74%) имеют  $p\text{-value} < 0.05$  в точном тесте Фишера. При проведении 10000 случайных пермутаций уровней значимости по генам, в данном

опероне в среднем наблюдалось 3% перепредставленных генов, а максимальная доля составила 21%. Таким образом, можно сделать вывод, что повышенная представленность данного оперона в изолятах из пациентов, но не здоровых людей, не является случайным наблюдением. Полный список оперонов, определенных как значимо чаще встречающихся у изолятов из пациентов с болезнью Крона приведен в таблице 1.

Таблица 1 — Список оперонов статистически значимо пере-представленных в группе штаммов *E. coli* изолированных от пациентов с болезнью Крона. N - количество генов, Pobs - наблюдаемая доля перепредставленных генов в опероне, Pmean - средняя доля перепредставленных генов при случайных пермутациях, Pmax - максимальная доля перепредставленных генов при случайных пермутациях.

N	Pobs	Pmean	Pmax	функция
4	1	0.03	0.75	утилизации глиоксилата
6	0.83	0.02	0.67	синтез и экспорт капсулы
6	1	0.02	0.67	захват гемина
7	0.86	0.03	0.57	утилизации сорбозы
19	0.74	0.03	0.21	утилизации пропандиола

## Разработка и применение графового подхода для визуализации локальной вариабельности геномов

Множество сочетаний генов, встречающихся в наборе геномов, можно представить в виде графа и использовать его для визуализации сравнений геномных последовательностей. Преимуществом данного подхода является компактность визуализации, так что становится возможным сравнение генных контекстов в сотнях геномных последовательностях. Компактность достигается за счет того, что сочетание генов, одинаковое для всех геномов, представляется при помощи одного ребра, вне зависимости от количества геномов. Новые узлы и ребра добавляются в граф только когда соответствующие сочетания ранее не наблюдались.

Визуализация полного графа для набора геномов возможна в случае небольших вирусных геномов; в случае бактериальных геномов имеет смысл проводить визуализацию и анализ подграфа — части полного графа, соответствующей некоторому региону интереса (например, оперону).

Алгоритм построения подграфа схож с описанным выше. Первым шагом является построение референсной цепочки узлов — узлов графа, которые соответствуют генам референсного генома расположенным в выбранном регионе. Далее, в подграф включаются все пути, которые начинаются или заканчиваются на референсной цепочке. Мы предусмотрели несколько фильтров, позволяющих снизить количество отображаемых узлов и ребер. Фильтр минимального веса



ребра позволяет отсечь ребра, которые представляют редкие сочетания генов (встречающиеся в небольшом количестве геномов). Фильтр длинных путей заменяет слишком протяженные цепочки узлов (они могут появиться в результате геномных перестроек) на короткие фрагменты ("хвосты") некоторой заданной длины.

Визуализация подграфов обладает практической ценностью, поскольку позволяет создавать наглядную визуализацию возможных сочетаний генов в определенной области генома. Подобный тип визуализации можно использовать для определения того, представлен ли некоторый оперон в одном и том же геномном контексте, или в разных. Под геномным контекстом мы понимаем гены, расположенные непосредственно перед и после оперона. Мы говорим об одинаковом контексте в случае, если гены перед опероном относятся к одной ортогруппе, и гены после оперона относятся к некоторой другой ортогруппе. В графовом представлении при этом мы будем наблюдать, что цепочка узлов, соответствующая генам оперона, будет соединена с одним узлом с одной стороны и с другим узлом — с другой.

## Примеры применения графового подхода для визуализации сравнения геномов

Рассмотрим, как выглядят подграфы, соответствующие некоторым из оперонов статистически значимо чаще встречающихся у изолятов *E. coli* полученных от пациентов с болезнью Крона, по отношению к изолятам от здоровых людей. На этих примерах будут проиллюстрированы основные моменты анализа графового представления фрагментов генома.




Рис. 5 — Граф представляющий окрестность оперона утилизации гема (hemin uptake, hmu). В ряде геномов оперон отсутствует, что видно из наличия ребра в графе, которое начинается перед и заканчивается непосредственно после генов оперона.

На рисунке 5 показан граф, построенный в окрестности оперона захвата гема (hemin uptake, hmu). Как видно из графа, данный оперон расположен в консервативном геномном контексте. Дуговое ребро обходящее оперон сверху говорит о том, что в некотором наборе геномов данный оперон отсутствует и других последовательностей генов в этом локусе не наблюдается.

На рисунке 6 показан граф, построенный в окрестности оперона утилизации пропандиола (propanediol utilization operon, pdu). Оперон утилизации пропандиола также имеет одинаковый контекст в разных геномах. Ребро обходящее оперон (дуга ниже оперона) говорит о том, что в ряде штаммов в данном контексте нет иных вариантов последовательностей генов. Наблюдается некоторая вариабельность внутри оперона, соответствующая нескольким вариантам данного оперона. Помимо pdu оперона, в том же контексте у ряда штаммов представлен альтернативный набор генов. В этот альтернативный набор входят гены транспорта железа (FepC, FcuA, HmuU), гены мобильных элементов (retroviral integrase core domain, transposase DDE Tnp ISL3) и множество гипотетических генов с неизвестной функцией. Примечательна вариабельность этого альтернативного набора генов. Вероятно, данный участок генома часто служит местом рекомбинационных событий, приводящих к изменению генов, причем эти изменения часто накладываются друг на друга (вероятно, не сайт специфичны).




Рис. 6 — Граф представляющий окрестность оперона утилизации пропандиола (propanediol utilization operon, pdu). Видна значительная вариабельность генного состава в данном регионе, что отражено во множестве путей на графе обходящих область генов оперона.

На рисунке 7 показано ближайшее окружение кластера генов отвечающего за синтез и транспорт полисахаридов бактериальной капсулы группы 2 (описана как остров патогенности капсульной сборки IV у *E. coli* LF82). Видно, что оперон состоит из консервативных фрагментов, окружающих вариабельный участок. Вариабельная часть оперона соответствует генам, отвечающим за синтез серотип-специфичного набора полимеров капсулы; гены консервативной части кодируют белки, участвующие в транспорте синтезированных веществ через клеточную стенку.

Таким образом, предложенный нами способ визуализации позволяет определить общую вариабельность генного состава в определенном локусе генома, выявить встречающиеся варианты взаимного расположения генов внутри оперона и найти вариабельные и консервативные области оперонов при их наличии.




Рис. 7 — Граф представляющий окрестность кластера генов синтеза и транспортировки компонент бактериальной капсулы.

## Разработка компьютерного приложения для анализа вариабельности геномов

Оценка профиля изменчивости и визуализация подграфов — это варианты анализа геномной изменчивости на различных уровнях: на уровне хромосомы или плазмиды в первом случае и на уровне небольших геномных локусов (например, оперонов) — во втором. Для проведения анализа на двух уровнях одновременно мы разработали приложение Genome Complexity Browser (GCB). Данное приложение доступно по адресу <https://gcb.rcpcm.org>, и может быть запущено на локальном компьютере пользователя. Веб-версия содержит данные о геномной изменчивости для 143 видов прокариот. Использование локальной версии необходимо для анализа групп геномов не представленных на веб-сервере.

Основные сценарии использования программы следующие:

I. Если интерес представляет некоторый оперон или группа генов.

Пользователь выбирает организм, геном и задает координаты области интереса. Происходит построение подграфа для выбранной области. При необходимости, пользователь меняет параметры визуализации (например, если получаемый граф слишком сложен для анализа можно увеличить минимальный отображаемый вес ребра для исключения редко встречающихся комбинаций генов). Доступен экспорт визуализации подграфа в графическом формате, либо в формате XML для последующей визуализации его в программе Cytoscape или иных редакторах графов.

II. Если интерес представляют области повышенной либо пониженной изменчивости генома.

Пользователь выбирает организм и геном. Происходит визуализация профиля изменчивости выбранного генома. Пользователь может выбрать интересующий его регион генома (например, область с максимальным уровнем изменчивости) и выполнить визуализацию подграфа в данной области - таким

образом можно установить, какие гены содержатся в данном локусе у различных геномов, и каков паттерн изменений. Пользователь может экспортировать профиль изменчивости в виде текстового файла для последующей визуализации (например, для сравнения профилей изменчивости разных организмов), либо сохранить области с повышенной изменчивостью в файл в формате BED.

Документация и видеоматериалы по использованию программы (как веб-версии, так и консольных утилит) доступны по адресу <https://gcb.readthedocs.io/>.

## Заключение

В настоящей работе реализовано представление набора геномов в виде графа для численной оценки уровня изменчивости в отдельных локусах генома и визуализации подграфов соответствующих отдельным областям генома.

Визуализация подграфов позволяет дать ответы на ряд вопросов о контексте генов интереса. Например, находится ли ген или гены интереса в одинаковом окружении во всех рассматриваемых геномах? Какие альтернативные генные контексты существуют и в каких геномах они представлены? Какие части набора генов (например, оперона или генного острова) являются консервативными, а какие вариабельными? Какие геномы содержат определенную комбинацию генов?

При помощи графового представления геномов мы реализовали метод количественной оценки локальной изменчивости, основанный на поиске уникальных путей в подграфе. Под изменчивостью в данном случае мы понимаем изменение состава либо взаимного расположения генов в геноме. Под локальностью — то, что изменения затрагивают небольшую область генома, не превышающую размер выбранного окна анализа (выбирается пользователем, обычно составляет около 20-40 генов). Насколько нам известно, разработанный нами вычислительный конвейер (Genome Complexity Browser, GCB) является первым доступным инструментом, позволяющим количественно определять изменчивость генома на основе заданного пользователем набора геномов. GCB предоставляет способ оценки профиля изменчивости вдоль репликонов, что позволяет находить "горячие" области генома, в которых уровень изменчивости значительно выше, чем в остальной части генома, и его "тихие" области. Проведенный анализ показал, что значительная часть высокоизменчивых областей генома соответствует местам встройки профагов и островов патогенности. В то же время, для кишечной палочки мы также наблюдали существование протяженной высокоизменчивой области генома, в которой нет признаков мобильных элементов. При этом данная область обладает высоким уровнем изменчивости у всех крупных филогрупп данного вида.

Мы провели поиск оперонов, которые чаще встречаются у кишечных палочек, выделенных из образцов фекалий и кишечных смывов пациентов с болезнью Крона — тяжелого воспалительного заболевания кишечника. Функция большинства найденных оперонов ясна, они позволяют захватывать железо,

утилизировать пропандиол (продукт переработки слизистого слоя), менять антигенные свойства, тем самым убегая от иммунного ответа. Интересно, что анализ графов, представляющих контекст этих генов, показал очень разные картины. Два оперона: утилизации пропандиола и производства капсулы находятся в высокоизменчивых —”горячих” — областях генома. Опероны утилизации гемина, утилизации глиоксилата, захвата сорбозы напротив находятся в ”тихих” областях. Роль генетических факторов, находящихся в областях генома с разным уровнем изменчивости, в формировании генотипа и фенотипа бактерий — предмет дальнейших исследований. В случае оперона синтеза и экспорта капсульных полисахаридов, можно предположить, что нахождение данного оперона в ”горячей” области генома может способствовать более высокой изменчивости состава оперона (у него есть высоко вариативная часть, отвечающая за синтез капсулы), что в свою очередь выгодно для эффективного избегания иммунного ответа организма-хозяина.

## Выводы

1. Графовое представление геномов позволяет эффективно проводить поиск областей генома с повышенной изменчивостью.
2. Геномы представителей различных филогрупп и филогенетически близких видов прокариот имеют консервативно расположенные области повышенной изменчивости (расположенные в местах генома с одинаковым генным контекстом).
3. Уровень геномной изменчивости ассоциирован с плотностью хромосомных контактов (коэффициент корреляции составил -0.36) и плотностью расположения сайтов Chi (коэффициент корреляции составил -0.25).
4. Следующие опероны значимо чаще ( $p\text{-value} < 0.0001$ ) встречаются в изолятах *E. coli* от пациентов с болезнью Крона: захват сорбозы, захват гемина, утилизации глиоксилата, утилизации пропандиола, синтеза и экспорта капсульных полисахаридов.
5. Опероны значимо чаще встречающиеся в изолятах *E. coli* от пациентов с болезнью Крона расположены в высокоизменчивых областях (опероны утилизации пропандиола, синтеза и экспорта капсульных полисахаридов) и в консервативных участках генома (захват сорбозы, захват гемина, утилизации глиоксилата).

а

## Публикации автора по теме диссертации

В изданиях, входящих в международную базу цитирования Web of Science

1. Genome Complexity Browser: Visualization and quantification of genome variability / A. Manolov [и др.] // PLoS computational biology. — 2020. — Т. 16, № 10. — e1008222.
2. Genetic diversity of *Escherichia coli* in gut microbiota of patients with Crohn's disease discovered using metagenomic and genomic analyses / A. V. Tyakht [и др.] // BMC genomics. — 2018. — Т. 19, № 1. — С. 1–14.
3. Ultrahigh-throughput functional profiling of microbiota communities / S. S. Terekhov [и др.] // Proceedings of the National Academy of Sciences. — 2018. — Т. 115, № 38. — С. 9551–9556.
4. Genome analysis of *E. coli* isolated from Crohn's disease patients / D. V. Rakitina [и др.] // BMC genomics. — 2017. — Т. 18, № 1. — С. 1–17.
5. Bulaev, A. Genome analysis of *Acidiplasma* sp. MBA-1, a polyextremophilic archaeon predominant in the microbial community of a bioleaching reactor / A. Bulaev, A. Kanygina, A. Manolov // Microbiology. — 2017. — Т. 86, № 1. — С. 89–95.
6. Outer membrane vesicles secreted by pathogenic and nonpathogenic *Bacteroides fragilis* represent different metabolic activities / N. B. Zakharchevskaya [и др.] // Scientific reports. — 2017. — Т. 7, № 1. — С. 1–16.

#### **В сборниках трудов конференций**

7. Метод анализа контекста генов и интенсивности геномных перестроек в бактериальных геномах / А. Манолов [и др.] // “ПОСТГЕНОМ’2018”, Казань. — 2018. — С. 219.
8. Сравнительный анализ частоты геномных перестроек у прокариот / А. Манолов [и др.] // “VI Съезд биохимиков России.” — 2019. — С. 144.
10. Поиск генов бактерий вида *Escherichia coli* ассоциированных с болезнью Крона / А. Манолов [и др.] // ВЫСОКОПРОИЗВОДИТЕЛЬНОЕ СЕКВЕНИРОВАНИЕ В ГЕНОМИКЕ II Всероссийская конференция с международным участием. — 2017. — 46а.
11. Поиск генов бактерий вида *Escherichia coli* ассоциированных с болезнью Крона / А. Манолов [и др.] // БИОТЕХНОЛОГИЯ: СОСТОЯНИЕ И ПЕРСПЕКТИВЫ РАЗВИТИЯ Москва, 20–22 февраля 2017 года. — 2017. — С. 487–489.
12. Сборка de-novo и сравнительный анализ генома бактерии *P. stutzeri* KOS6, извлеченной из нефтяного шламма / А. Манолов [и др.] // “HIGH-THROUGHPUT SEQUENCING IN GENOMICS” Новосибирск, 21–25 июля 2013 года. — 2013. — С. 53.
14. Поиск генетических маркеров бактерий вида *Escherichia coli*, ассоциированных с болезнью Крона / А. Манолов [и др.] // “V СЪЕЗД БИОХИМИКОВ РОССИИ”, Дагомыс. — 2016. — С. 114.

*Манолов Александр Иванович*

Биоинформатический анализ изменчивости генного состава прокариот, в том числе в  
ассоциации с патогенностью

Автореф. дис. на соискание ученой степени канд. биол. наук

Подписано в печать \_\_\_\_\_.\_\_\_\_\_.\_\_\_\_\_. Заказ № \_\_\_\_\_

Формат 60×90/16. Усл. печ. л. 1. Тираж 100 экз.

Типография \_\_\_\_\_

